Praxisprojekt: Programmierung in Python

Einleitung

Die Projektarbeit "Programmierung in Python" soll in einem Team von 3 - 4 Studierenden bearbeitet werden. Für ein erfolgreiches Bestehen des Kurses sind folgende Voraussetzungen zu erfüllen:

- Aufgabe 1 sowie Aufgabe 2 sind vollständig zu bearbeiten.
- Gemeinsame Vorstellung der Projektergebnisse im letzten Praxistermin (ca. 10 15 Minuten pro Team)
- Beantwortung der Fragen zum Projekt und zum Vorlesungsinhalt (ca. 5 Minuten pro Person)
- Abgabe des dokumentierten Projektergebnisses in Form einer (PowerPoint)-Präsentation oder (Latex-)Skriptes* pro Team

Gemeinsame Vorstellung der Projektergebnisse im letzten Praxistermin

Beschreibung

Die Daten, welche in dieser Challenge verwendet werden sollen, finden Sie in der Datei vehicle_data.xlsx. Bitte beachten Sie, dass die Daten zunächst aufbereitet werden müssen, also noch nicht in einer Qualität vorliegen, die eine finale Insight-Generierung ermöglicht.

Die Quelldatei vehicle_data.xlsx beinhaltet Daten zu 500 Fahrzeugen:

Im Reiter sales code finden Sie 500 Trucks deren eindeutige Fahrzeugidentifikationsnummer (FIN) als hash in der Spalte h_vehicle_hash dargestellt ist. Jedes Fahrzeug ist aufgeschlüsselt nach Produktionsdatum, Land in welches das Fahrzeug verkauft wurde und sales_code_array. Letztere Spalte beinhaltet Codes, welche die genaue Zusammensetzung des Fahrzeuges† beschreiben. Im Reiter engines finden Sie 9 sales Codes, die Aufschluss darüber geben, welcher Motor‡ im entsprechenden Fahrzeug verbaut ist.

^{*}Weitere Anforderungen an die schriftliche Abgabe sind der Orga.pdf Datei zu entnehmen

[†]verbauter Motor, Leistungsklasse, Kabinentyp und weitere Merkmale

 $^{^{\}ddagger}\mathrm{OM924},\ \mathrm{OM926},\ \mathrm{etc}\ \ldots$

Mit der Tabelle vehicle_hash können Sie die gehashte FIN zurück in die originale Darstellung§ mappen.

Bevor Sie starten, bietet es sich an sich zunächst mit den Datenätzen vertraut zu machen. Verschaffen Sie sich einen Überblick und erkunden Sie die Zusammenhänge der Datensätze.

 $[\]S 17$ stellige Buchstaben-Zahlenkombination

Aufgabe 1: Data Engineering

Schreiben Sie eine ETL Pipeline zur Datenaufbereitung. Gehen Sie dabei wie folgt vor.

- Daten laden
- Daten bereinigen und aufbereiten
- Daten zusammenführen
- Gesamttabelle bestehend aus folgenden Spalten abspeichern:
 - fin
 - production_date
 - country
 - sales_code_array

Aufgabe 2: Data Science

Analysieren Sie den die Daten, indem Sie folgende Fragestellungen auswerten. Visualisieren Sie ihre Ergebnisse.

- Welches sind die top drei Länder, in die wir zwischen 01.01.2014 und 31.12.2020 am meisten Fahrzeuge verkauft haben.
- In welchem dieser Jahre haben wir insgesamt am meisten Fahrzeuge verkauft?

Aufgabe 2: Data Science (optional)

- Welche FIN hat das zeitlich erste verkaufte Fahrzeug.
- Wie viele Fahrzeuge wurden zwischen 01.01.2017 und 01.01.2021 mit OM934, OM936, OM470 und OM471 Motoren verkauft.
- Welche Fahrzeuge (FIN) wurden zwischen 01.01.2017 und 01.01.2021 und mit OM936 Motor nach Neuseeland verkauft.